Машинное обучение

Лекция 1

Введение

Ковалев Евгений

ekovalev@hse.ru

НИУ ВШЭ, 2020

Организационные моменты

• Чат:



• Материалы курса:



https://github.com/KovalevEvgeny/dpo-ml-2020

• Ваша настольная энциклопедия:



Организационные моменты

- Домашние задания: примерно 6-7
- Проверочные работы: на каждом занятии (на несколько минут)
- 10-балльная система

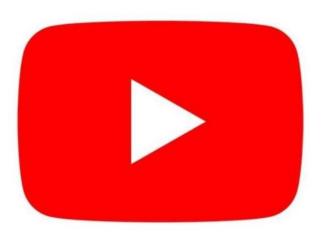
• Оценка:

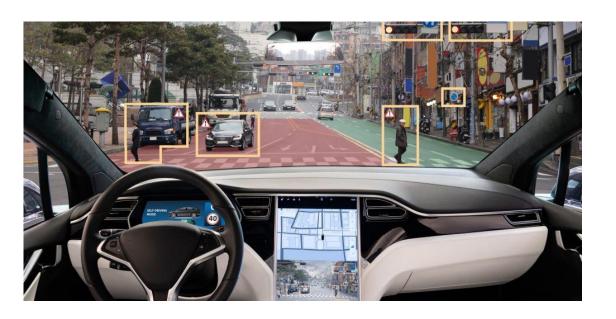
$$O_{\text{итоговая}} = 0.8 * Д3 + 0.2 * ПР$$

• Для зачета нужно получить 6 и выше





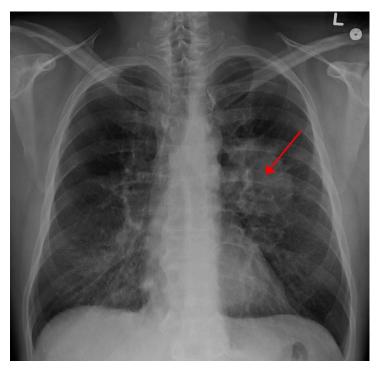






https://wyscout.com/







https://www.nature.com/articles/d41586-020-00018-3#:~:text=The%20researchers%20say%20the%20antibiotic,with%20artificial%20intelligence%20(AI).&text=Bacterial%20resistance%20to%20antibiotics%20is,people%20per%20year%20by%202050.



https://www.youtube.com/watch?v=cBRgoQGn6gQ



https://builtin.com/healthcare-technology/augmented-virtual-reality-surgery

Искусственный интеллект?



https://www.youtube.com/watch?v=kopoLzvh5jY



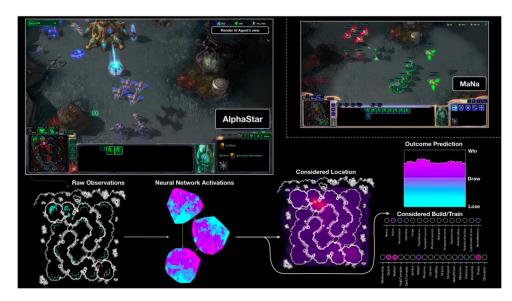
https://deepmind.com/research/case-studies/alphago-the-story-so-far



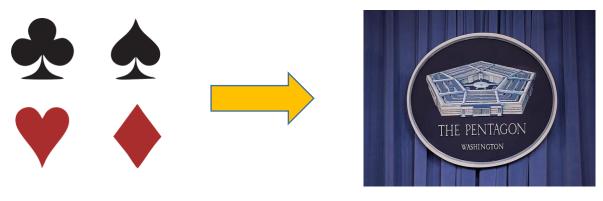
https://openai.com/projects/five/



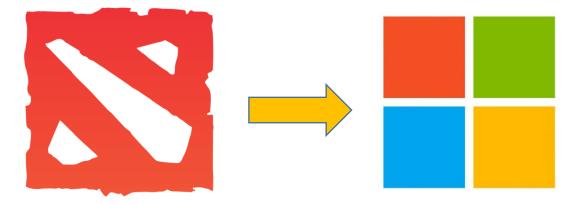
https://nplus1.ru/news/2017/12/18/ai-poker-details



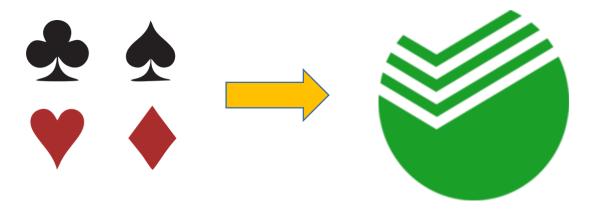
 $\underline{https://deepmind.com/blog/article/alphastar-mastering-real-time-strategy-game-starcraft-ii}$



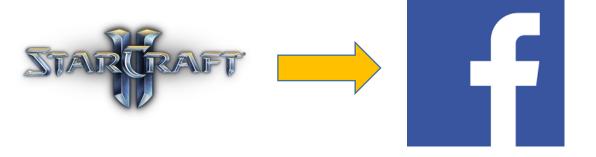
https://www.wired.com/story/poker-playing-robot-goes-to-pentagon/



https://www.theverge.com/2019/7/22/20703578/microsoft-openai-investment-partnership-1-billion-azure-artificial-general-intelligence-agi

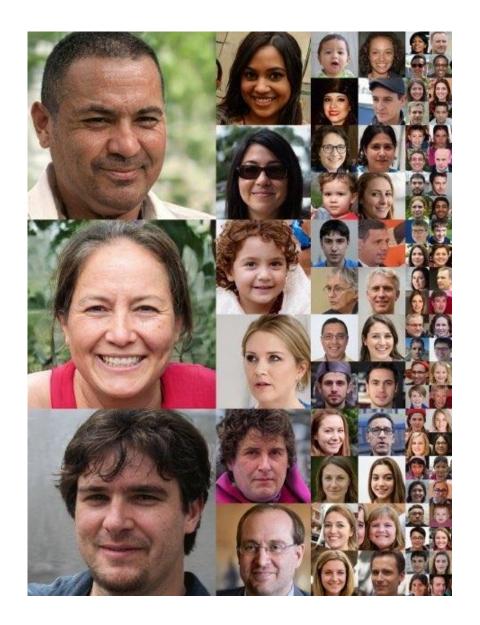


https://vc.ru/flood/26141-sberbank-holdem



 $\underline{https://www.wired.com/story/facebook-quietly-enters-starcraft-war-for-ai-bots-and-loses/}$

Что общего у всех этих людей?

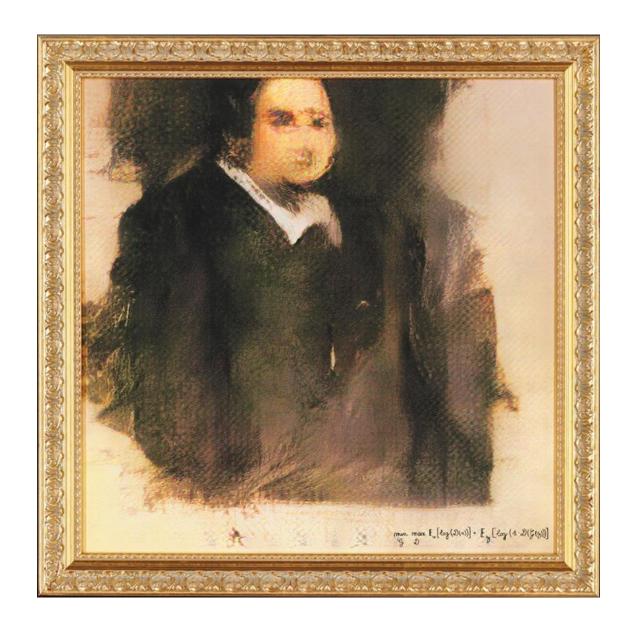


Что общего у всех этих людей?

Их не

https://thispersondoesnotexist.com/





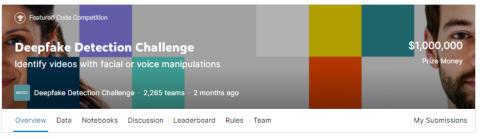
Al artwork sells for \$432,500 — nearly 45 times its high estimate — as Christie's becomes the first auction house to offer a work of art created by an algorithm

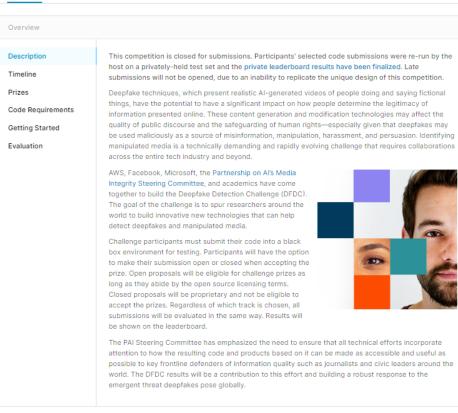
https://www.christies.com/features/A-collaboration-between-two-artists-one-human-one-a-machine-9332-1.aspx

Deep Fakes



https://www.youtube.com/watch?v=kqKgCB4hJw4





https://www.kaggle.com/c/deepfake-detection-challenge



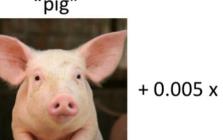
?

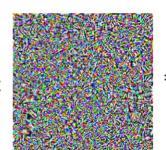
https://findface.pro/blog/ochertania-budushego-ot-ntechlab-raspoznavanie-siluetov/



Adversarial attacks

"pig"







https://neurips.cc/Conferences/2019/Schedule?showEvent=14481



https://www.youtube.com/watch?v=MIbFvK2S9g8



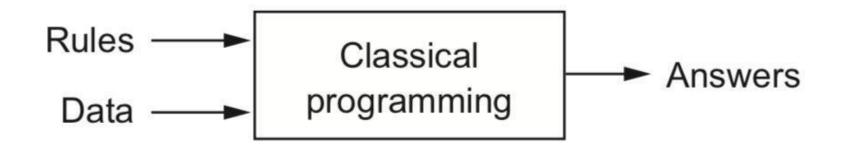
https://www.dezeen.com/2019/07/30/ewanowak-anti-ai-mask-protects-wearers-from-masssurveillance/

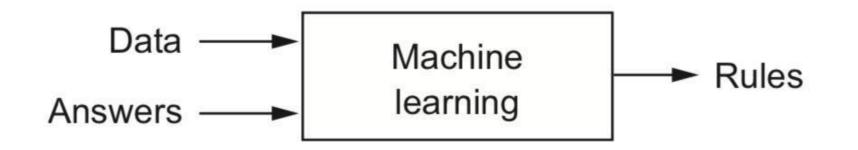
People with no idea about AI, telling me my AI will destroy the world

Al



Что такое машинное обучение?





Пример задачи*

• Как определить стоимость дома?



^{*}https://www.kaggle.com/c/house-prices-advanced-regression-techniques

Пример задачи

- Как определить стоимость дома,
- ...зная стоимость 1000 других домов?











Больше сложных задач!

- Какой будет спрос на товар в следующем месяце?
- Какой оттенок у отзыва, оставленного клиентом?
- Вернет ли клиент кредит?
- Заболеет ли пациент раком?
- Сдаст ли студент следующую сессию?
- Сколько лет человеку на фотографии?
- Сколько времени тратят рабочие на обед?

Машинное обучение

- Везде очень сложные неявные зависимости
- Нельзя выразить их формулой
- Но есть некоторое число примеров
- Будем восстанавливать (приближать) исходные зависимости, используя конечное число примеров

Основные термины

Пример задачи*

- Сеть ресторанов
- Хотим открыть еще один
- Несколько вариантов размещения
- Какой из вариантов принесет максимальную прибыль?

*https://www.kaggle.com/c/restaurant-revenue-prediction



Обозначения

- *x* объект, sample для чего хотим делать предсказания
 - Конкретное расположение ресторана
- Х пространство всех возможных объектов
 - Все возможные расположения ресторанов
- y ответ, целевая переменная, target что предсказываем
 - Прибыль в течение первого года работы
- \mathbb{Y} пространство ответов все возможные значения ответа
 - Все вещественные числа

Обучающая выборка

- Мы ничего не понимаем в экономике
- Зато имеем много объектов с известными ответами
- $X = (x_i, y_i)_{i=1}^{\ell}$ обучающая выборка
- ℓ размер выборки

- Объекты абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features числовые характеристики объектов
- d количество признаков
- $x = (x_1, ..., x_d)$ признаковое описание объекта

- Объекты абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features числовые характеристики объектов
- d количество признаков
- $x = (x_1, ..., x_d)$ признаковое описание объекта



- Объекты абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features числовые характеристики объектов
- d количество признаков
- $x = (x_1, ..., x_d)$ признаковое описание объекта



- Про демографию:
 - Средний возраст жителей ближайших кварталов
 - Динамика количества жителей
- Про недвижимость:
 - Средняя стоимость квадратного метра жилья поблизости
 - Количество школ, банков, магазинов, заправок
 - Расстояние до ближайшего конкурента
- Про дороги:
 - Среднее количество машин, проезжающих мимо за день

Алгоритм

- a(x) алгоритм, модель функция, предсказывающая ответ для любого объекта
- Отображает 🛚 в 🖺
- Например, линейная модель: $a(x) = w_0 + w_1 x_1 + \dots + w_d x_d$

$$a(x) = 1.000.000 + 100.000 * (расстояние до конкурента) $-100.000 * (расстояние до метро)$$$

Функция потерь

- Не все алгоритмы полезны нужно как-то оценивать их качество
- a(x) = 0 не принесет никакой выгоды
- Предсказали \$10000 прибыли, а она на самом деле \$5000 хорошо или плохо?
- Функция потерь L(a,x) функция, характеризующая величину ошибки алгоритма a на объекте x
- Квадратичное отклонение: $L(a, x) = (a(x) y)^2$
- Чем меньше, тем лучше

Функционал качества

- Функционал качества, метрика качества мера качества работы алгоритма на выборке
- Среднеквадратичная ошибка (Mean Squared Error, MSE):

$$Q(a,X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

Функционал качества

- Должен соответствовать бизнес-требованиям
- Одна из самых важных составляющих анализа данных

Обучение алгоритма

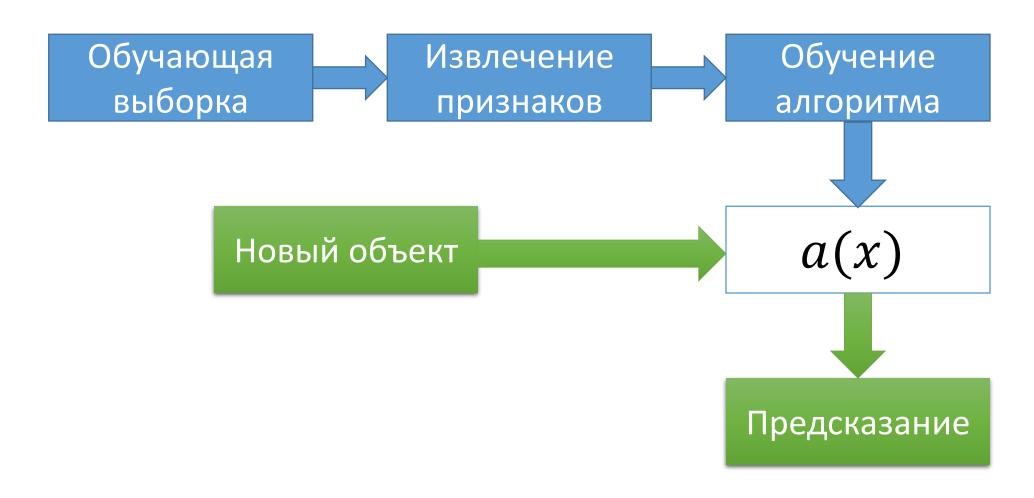
- Есть обучающая выборка и функционал качества
- ullet Семейство алгоритмов ${\mathcal A}$
 - Из чего выбираем алгоритм
 - Пример: все линейные модели
 - $\mathcal{A} = \{ w_0 + w_1 x_1 + \dots + w_d x_d \mid w_0, w_1, \dots, w_d \in \mathbb{R} \}$
- Обучение: поиск оптимального алгоритма с точки зрения функционала качества

Машинное обучение

• Не все задачи имеют такую формулировку!

- Обучение без учителя
- Обучение с подкреплением
- И т.д.

Машинное обучение



Что нужно знать

- 1. Как сформулировать задачу?
- 2. Какие признаки использовать?
- 3. Откуда взять обучающую выборку?
- 4. Как выбрать метрику качества?
- 5. Как обучить алгоритм?
- 6. Как оценить качество алгоритма?

Как можно заниматься анализом данных?

Data scientist

- Работа с данными
- Знание инструментов и методов
- Опыт решения задач

• Менеджер

- Понимание, как работает машинное обучение
- Понимание узких мест, оценивание сроков

• Заказчик

- Метрики качества
- Требования к данным
- Ограничения современных подходов

На следующей лекции

- Типы задач в машинном обучении
- Типы признаков
- Примеры задач
- Линейная регрессия